

UNIVERZITET U BEOGRADU
MATEMATIČKI FAKULTET

Projekat iz predmeta
Istraživanje podataka 2

Tema:
**Klasterovanje multimodalnih senzorskih
podataka na MEx skupu podataka**

Student:
Mateja Milošević 31/2021

Beograd, 2026.

Sadržaj

1	Opis zadatka	2
2	O MEx datasetu	2
2.1	Senzori	2
2.2	Metapodaci	2
3	Vizuelizacija podataka	3
3.1	3D putanje akcelerometara	3
3.2	2D toplotne mape	4
4	Preprocesiranje podataka	6
4.1	Čišćenje podataka	6
4.2	Redukcija dimenzionalnosti (PCA)	6
4.3	Ekstrakcija obeležja	6
4.4	Standardizacija	6
4.5	Čuvanje preprocesiranih podataka	6
5	Primenjeni algoritmi	6
5.1	Metrike za evaluaciju	7
6	Rezultati i analiza	7
6.1	Prva faza: osnovna obeležja (mean, std, min, max)	7
6.2	Pretraga podskupova senzora (prva faza)	7
6.3	Druga faza: proširena obeležja (mean, std, RMS, raspon)	8
6.4	Pretraga podskupova senzora (druga faza)	8
6.5	Analiza rezultata	9
6.6	Vizuelizacija klastera	9
7	Čuvanje modela	10
8	Zaključak	10
8.1	Struktura projekta	10
9	Literatura	11

1 Opis zadatka

Cilj ovog projekta je da na osnovu podataka sa senzora grupišemo sesije vežbanja i vidimo da li klasteri odgovaraju stvarnim vežbama. Koristimo MEx dataset koji sadrži snimke sa više senzora dok ispitanici rade fizioterapeutske vežbe. Ideja je da primenimo algoritme klasterovanja i proverimo koliko dobro mogu da prepoznaju koja je vežba u pitanju, bez da im kažemo unapred.

U projektu radimo sledeće:

- Preprocesiramo sirove senzorske podatke (čišćenje, redukcija dimenzija, ekstrakcija obeležja)
- Primenujemo 5 različitih algoritama klasterovanja
- Isprobavamo razne kombinacije senzora i poredimo rezultate
- Čuvamo najbolje modele na disk

2 O MEx datasetu

MEx (Multi-modal Exercise) dataset sadrži snimke **7 fizioterapeutskih vežbi** koje je radilo **30 ispitanika**. Svaka vežba traje do 60 sekundi. Ukupno imamo **239 sesija** - svaki ispitanik ima 8 sesija (7 vežbi + vežba 4 se radi na obe strane tela), osim ispitanika 22 koji ima 7.

2.1 Senzori

Podaci su prikupljeni sa 4 senzora:

Tabela 1: Pregled senzora u MEx skupu podataka

Oznaka	Senzor	Opis
act	Axivity AX3 akcelerometar (butina)	3 ose, 100 Hz, meri ubrzanje noge
acw	Axivity AX3 akcelerometar (zglob ruke)	3 ose, 100 Hz, meri ubrzanje ruke
pm	Sensing Tex prostirka pritiska	$32 \times 16 = 512$ senzorskih tačaka, 15 Hz
dc	Intel Astra dubinska kamera	$12 \times 16 = 192$ tačke dubine, 15 Hz

Ispitanici su ležali na prostirci pritiska dok su radili vežbe. Kamera je bila postavljena iznad, okrenuta nadole, tako da snima odozgo.

2.2 Metapodaci

Iz naziva CSV fajlova izvlačimo tri informacije za svaku sesiju:


- **Subject** - id ispitanika (01 do 30)
- **Exercise** - koja vežba (1-7), ovo su nam labele za evaluaciju
- **Trial** - pokušaj/strana tela (vežba 4 ima trial 1 i 2, ostale samo 1)

3 Vizuelizacija podataka


Pre obrade smo vizuelno pregledali podatke da vidimo šta koji senzor zapravo beleži.

3.1 3D putanje akcelerometara

Nacrtali smo 3D putanje akcelerometra na butini za vežbu 4, koja se radi na obe strane. Trial 1 (slobodna noga) pokazuje da senzor uglavnom miruje jer leži na podu ($Z \approx -1g$), dok Trial 2 (noga sa senzorom) prikazuje ceo luk pokreta u prostoru. Takođe smo nacrtali 3D potpise za sve ostale vežbe da vidimo kako se razlikuju - svaka vežba ima prepoznatljivu putanju.




Slika 1: 3D putanja akcelerometra na butini (vežba 4, Trial 1 vs Trial 2)




Slika 2: 3D putanje akcelerometra na zglobo ruke za različite vežbe

3.2 2D toplotne mape

Za prostirku pritiska (pm) nacrtali smo sekvenco od 20 frejmov, ki prikazujejo, kako se raspored pritiska telesa menja med treningom. Vidi se, kako se teža prebaca s ene strani na drugo. Isto smo naredili za dubinsko kamero (dc), kjer frejmovi prikazujejo silueto telesa od zgoraj.



Slika 3: Toplotna mapa pritiska na prostirci tokom vremena (vežba 1)



Slika 4: Dubinska kamera - 20 frejmova siluete (vežba 1)

4 Preprocesiranje podataka

Pre nego što primenimo algoritme klasterovanja, moramo da sredimo podatke. Ovo je rađeno u nekoliko koraka.

4.1 Čišćenje podataka

- **Akcelerometri (act, acw):** Nedostajuće vrednosti smo popunili linearnom interpolacijom, pa primenili rolling-mean filter sa prozorom od 5 frejmova da očistimo visokofrekventni šum.
- **Prostirka i kamera (pm, dc):** Nedostajuće vrednosti smo popunili nulama.

4.2 Redukcija dimenzionalnosti (PCA)

Prostirka ima 512 kolona po frejmu, a kamera 192 - to je previše za klasterovanje. Koristimo PCA da svedemo oba senzora na 15 glavnih komponenti koje čuvaju najveći deo informacije iz originalnih podataka.

4.3 Ekstrakcija obeležja

Pošto svaka sesija ima različit broj frejmova, moramo da ih svedemo na vektore iste dužine. Iz svake sesije za svaki senzor izvlačimo statistička obeležja po kanalu: srednju vrednost (mean), standardnu devijaciju (std), minimum i maksimum.

4.4 Standardizacija

Na kraju sve standardizujemo Z-score-om (`StandardScaler`) da senzori sa različitim mernim opsezima budu uporedivi.

4.5 Čuvanje preprocesiranih podataka

Obradene podatke čuvamo u folder `preprocessed_mex/`. Struktura foldera je ista kao u originalnim podacima.

5 Primenjeni algoritmi

Testiramo 5 algoritama klasterovanja. Pošto imamo 7 vežbi, svuda stavljamo `n_clusters=7`.

1. **K-Means** - klasičan algoritam koji traži 7 centroida i dodeljuje svaku tačku najbližem. Brz i jednostavan, ali pretpostavlja okrugle klustere.
2. **Agglomerative Clustering** - hijerarhijski pristup koji kreće od toga da je svaka tačka svoj klaster, pa ih spaja dok ne ostane 7.
3. **Spectral Clustering** - koristi matricu sličnosti i teoriju grafova. Prvo projektuje podatke u nižu dimenziju pa onda klasteruje.

4. **Gaussian Mixture Model (GMM)** - verovatnosni model koji pretpostavlja da podaci dolaze iz mešavine 7 Gausovih raspodela. Fleksibilniji od K-Means jer dozvoljava eliptične klastere.
5. **Birch** - hijerarhijski algoritam koji gradi stablo obeležja. Sličan Agglomerative-u ali optimizovan za veće skupove podataka.

5.1 Metrike za evaluaciju

Koristimo dve metrike:

- **Silhouette Score** - koliko su klasteri kompaktni i razdvojeni (od -1 do 1, veće je bolje).
- **Adjusted Rand Index (ARI)** - koliko se naši klasteri poklapaju sa pravim oznakama vežbi (1 je savršeno poklapanje, 0 je nasumično).

6 Rezultati i analiza

6.1 Prva faza: osnovna obeležja (mean, std, min, max)

Prvo smo testirali sve algoritme koristeći osnovna statistička obeležja sa svih senzora:

Tabela 2: Rezultati prve faze sa svim senzorima

Algoritam	Silhouette	ARI
Spectral Clustering	0.0779	0.6095
K-Means	0.0817	0.5427
Agglomerative Clustering	0.0723	0.5076
Birch	0.0723	0.5076
Gaussian Mixture Model	0.0906	0.3733

Spectral Clustering je bio najbolji sa ARI od 0.61. To je solidan početak, ali znači da dosta sesija i dalje završava u pogrešnom klasteru.

6.2 Pretraga podskupova senzora (prva faza)

Zatim smo isprobali sve kombinacije od 2 i 3 senzora da vidimo koji senzori najviše doprinose. Top 5 rezultata:

Tabela 3: Najbolje kombinacije senzora u prvoj fazi

Algoritam	Senzori	ARI
Spectral Clustering	act, pm, dc	0.6219
Birch	pm, dc	0.6202
Agglomerative	pm, dc	0.6202
Spectral Clustering	svi (act, acw, pm, dc)	0.6095
Agglomerative	act, pm, dc	0.6084

Zanimljivo je da kombinacija samo prostirke i kamere (**pm**, **dc**) daje skoro isto kao kad dodamo i akcelerometar. Takođe, akcelerometar sa zgloba (**acw**) se ne pojavljuje u najboljim rezultatima, što znači da u ovoj fazi uglavnom unosi šum.

6.3 Druga faza: proširena obeležja (mean, std, RMS, raspon)

Da bismo poboljšali rezultate, dodajemo još dva obeležja: RMS (snaga signala) i raspon/ptp (razlika max - min, meri amplitudu pokreta). Međutim, ovo dodajemo samo za akcelerometre (**act**, **acw**), jer za kameru i prostirku bi bilo previše dimenzija pa bi samo unelo šum.

Dakle obeležja su:

- **act** i **acw**: mean, std, RMS, ptp
- **pm** i **dc**: samo mean i std

Rezultati sa svim senzorima sa ovim novim obeležjima:

Tabela 4: Rezultati druge faze sa svim senzorima i proširenim obeležjima

Algoritam	Silhouette	ARI
Agglomerative Clustering	0.1101	0.8169
Birch	0.1101	0.8169
K-Means	0.1065	0.7077
Spectral Clustering	0.1041	0.6719
Gaussian Mixture Model	0.1092	0.6264

Značajan napredak u odnosu na prvu fazu. Agglomerative i Birch su skočili sa 0.51 na 0.82 ARI. Dodavanje RMS-a i raspona samo na akcelerometre je napravilo veliku razliku.

6.4 Pretraga podskupova senzora (druga faza)

Ponovo isprobavamo sve kombinacije senzora sa novim obeležjima. Top 10 rezultata:

Tabela 5: Najbolje kombinacije senzora u drugoj fazi (top 10)

#	Algoritam	Senzori	ARI
1	Gaussian Mixture Model	act, acw, dc	0.8254
2	Birch	act, acw, pm, dc	0.8169
3	Agglomerative	act, acw, pm, dc	0.8169
4	Agglomerative	act, dc	0.7727
5	Birch	act, dc	0.7727
6	Agglomerative	act, acw, dc	0.7508
7	Birch	act, acw, dc	0.7508
8	K-Means	act, acw, dc	0.7171
9	K-Means	act, dc	0.7140
10	Spectral Clustering	act, acw, dc	0.7096

Najbolji rezultat je GMM na kombinaciji **act**, **acw**, **dc** sa ARI od 0.8254, što znači da naš model tačno grupiše oko 82.5% sesija prema pravim vežbama.

6.5 Analiza rezultata

Iz ovih rezultata se mogu izvući neki zanimljivi zaključci.

Selektivna ekstrakcija obeležja daje mnogo bolje rezultate. Samo dodavanjem RMS-a i raspona na akcelerometre, bez komplikovanijih metoda, ARI je skočio sa oko 0.62 na oko 0.82. To pokazuje da su snaga i amplituda signala korisne za razlikovanje vežbi.


Akcelerometar na zglobo (acw) je koristan tek sa proširenim obeležjima. U prvoj fazi je uglavnom smetao i nije se pojavljivao u najboljim rezultatima, ali sa RMS-om i rasponom postaje vredan - najbolji rezultat ga uključuje.

Prostirka (pm) nije uvek potrebna. Najbolji model (GMM sa ARI 0.8254) koristi `act`, `acw`, `dc` bez prostirke.

GMM je nadmašio ostale na najboljoj kombinaciji senzora. Izgleda da GMM najbolje radi jer se prilagođava tome kako različiti ljudi rade iste vežbe.

6.6 Vizuelizacija klastera

Koristimo PCA da svedemo obeležja na 2 dimenzije i nacrtamo scatter plotove. Za svaki od 2 najbolja modela prikazujemo dva grafikona - levo tačke obojene po klasterima modela, desno iste tačke obojene po stvarnim vežbama, da možemo vizuelno da uporedimo.



Slika 5: PCA projekcije klastera: GMM (`act`, `acw`, `dc`) i Birch (`act`, `acw`, `pm`, `dc`) - predviđene vs stvarne klase

Na graficima se vidi da se klasteri uglavnom poklapaju sa pravim grupama, mada ima preklapanja između nekih sličnih vežbi. Treba imati u vidu da je PCA projekcija u 2D

samo aproksimacija i da u punom prostoru razdvajanje može biti bolje nego što izgleda na grafiku.

7 Čuvanje modela

Top 3 modela po ARI-ju automatski čuvamo u `models/` folder pomoću `joblib`-a. Kod dinamički čita rangiranu tabelu rezultata, ponovo trenira te modele i čuva ih. Naziv fajla sadrži ime algoritma i korišćene senzore.

Sačuvani modeli se mogu učitati sa:

```
1 import joblib
2 model = joblib.load('models/top1_gaussian_mixture_model_act_acw_dc.
   .pkl')
```

8 Zaključak

U ovom projektu smo pokazali da se fizioterapeutske vežbe mogu uspešno grupisati na osnovu senzorskih podataka. Krenuli smo od osnovnih statističkih obeležja gde je najbolji ARI bio oko 0.62, a dodavanjem RMS-a i raspona samo na akcelerometre smo došli do 0.82, što je poboljšanje od preko 20 procentnih poena.

Ukratko:

- Selektivna ekstrakcija obeležja (različita obeležja za različite tipove senzora) je efikasnija od uniformnog pristupa
- GMM se pokazao kao najbolji algoritam na optimalnoj kombinaciji senzora
- Kombinacija akcelerometara i dubinske kamere (`act`, `acw`, `dc`) daje bolje rezultate nego kad se doda i prostirka pritiska
- I sa relativno jednostavnim obeležjima (`mean`, `std`, `RMS`, `ptp`), bez složenih tehnika, moguće je postići dobre rezultate na ovom problemu

8.1 Struktura projekta

Sav materijal je organizovan tako da se može pokrenuti lokalno:

- `MEx.ipynb` - sveska sa kompletnim kodom
- `mex/data/` - originalni podaci
- `preprocessed_mex/` - preprocesirani podaci
- `models/` - sačuvani modeli
- `requirements.txt` - spisak biblioteka
- `.venv/` - virtuelno okruženje

9 Literatura

MEx skup podataka na UCI Machine Learning Repository: <https://archive.ics.uci.edu/dataset/500/mex>